AI 組織 Issue #19 「エントロピー削減の仕組み」

エントロピー削減システム

エージェントに関わる全 md ファイルを、意味を守りながら削る仕組み

埋め込みモデル 7 モデル実測（採用： ruri-v3-310m ）／次元削減は中心化しない SVD ／分離度の付録つき

実測日： 2026 年 11 月 8 日（ Muse VM ・ CPU 実測）／分離度の付録： 2026 年 11 月 10 日 追加

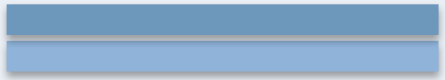
なぜ必要か

文書の自然増と、「減らす仕組み」の必要性

きっかけ： 毎回同じ作業でも、実行結果に揺れ。原因は、読み込む文書の膨張と、場所ごとの食い違い。

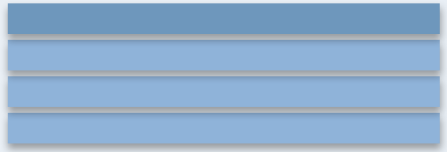
最初はすっきり

ルールの少数と、全体への目通し



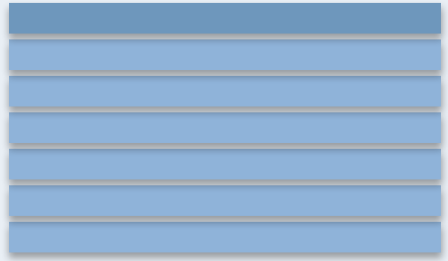
書き足しが続く

決め事・例外・事故の教訓のたびの追記



やがて肥大化

重複・古い記述・矛盾の混在と、大事なルールの埋没



探せない

増量に比例する、大事なルールの埋没

食い違う

同一内容の複数箇所への分散と、片側更新による矛盾

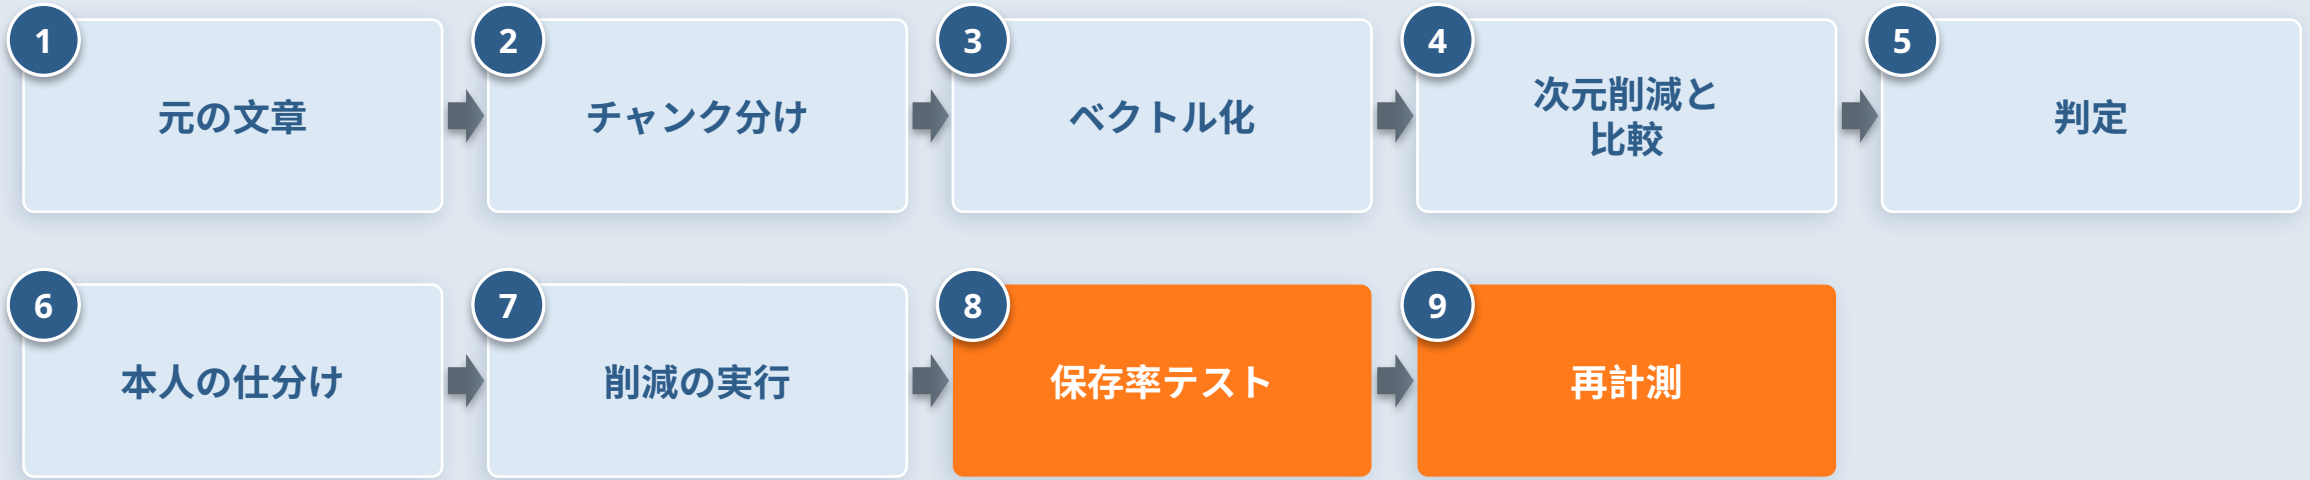
読まれない

長すぎる文書の未読化と、ルールの実質的な無効化

「増やす」は自然発生、「減らす」は仕組みなしでは不発生。 ゆえに、削減そのもののシステム化。

システム概要

9 段階の削減サイクルと、「意味の保存」という絶対の制約



再計測の結果は次サイクルの「測る」への入力 — 週次での循環

- 「測る → 候補 → 本人の仕分け → 削減の実行 → 再計測」までの一貫したコード担保（疎結合な小単位の組み合わせ）
- **保存率テスト：** 削減前の文書由来の固定質問セットへの、削減後の文書だけでの回答可能性の測定。合格ライン未満は削減不合格
- 到達可能性 100% の維持（コードへ移設した記述も到達可能として計数）
- 行数・削減率は非目標。対象は意味の保存のみ

実績

md ファイルの削減実績 — 常設 3 ファイルと、全 28 ファイル・ 1,275 行

AGENTS.md	**-22%**	13,171 → 10,281 B
TOOLS.md	**-31%**	15,273 → 10,535 B
MEMORY.md	**-2.8%**	35,058 → 34,092 B

毎回読み込まれる常設ファイルは上の 3 件（欠落ゼロを突合で確認）。リポジトリ側の全 md ファイルが下の 28 件:

skills RESULTS.md 364 → 廃止 **-364**	**watchdog design.md** 617 → 256 **-361**	**job-list architecture.md** 1633 → 1528 **-105**	**ai-org 決定履歴 .md** 92 → 廃止 **-92**	**int-notes 開発ノート .md** 89 → 廃止 **-89**	**job-list 引き継ぎ .md** 148 → 96 **-52**	**int-notes P3 計画 .md** 118 → 73 **-45**
skills CHANGELOG.md 34 → 廃止 **-34**	**job-list addendum.md** 32 → 廃止 **-32**	**entropy SPEC.md** 192 → 165 **-27**	**sheet-writer 要件対応表 .md** 49 → 36 **-13**	**watchdog design-notes.md** 46 → 36 **-10**	**skills PRODUCT.md** 66 → 56 **-10**	**skills eval/README.md** 50 → 43 **-7**
mac-conn CONNECTOR.md 90 → 82 **-8**	**sheet-writer README.md** 109 → 103 **-6**	**tool-catalog README.md** 45 → 40 **-5**	**ai-org 環境台帳 .md** 91 → 89 **-2**	**mac-conn gui_flow/README** 229 → 227 **-2**	**fortune README.md** 21 → 19 **-2**	**fortune skill/README.md** 7 → 5 **-2**
watchdog README.md 106 → 105 **-1**	**ai-org README.md** 28 → 27 **-1**	**ai-org 組織設計書 .md** 146 → 145 **-1**	**job-list README.md** 37 → 36 **-1**	**entropy README.md** 30 → 29 **-1**	**skills nj/README.md** 8 → 7 **-1**	**skills README.en.md** 156 → 155 **-1**

100 行以上　30 ～ 99 行　10 ～ 29 行　3 ～ 9 行　1 ～ 2 行

合計： 28 ファイル・ 1,275 行（廃止 5 ）

第 1 部

チャンク分け

文書を段落単位・最大 800 字の塊に分ける工程。後段のベクトル化・判定・保存率テストは、全てこの塊の単位での処理

段落単位・最大 800 字への分割 — 判定の最小単位の設計



区切り方の規則（実装どおり）

- **基本：** 空行で区切った段落を 1 チャンクとする。前後の空白は除去し、空の段落は対象外
- **800 字以内の段落：** そのまま 1 チャンク（段落＝意味の塊、という単位設定）
- **800 字を超える段落：** 800 字ごとに分割し、 100 字の重なりを持たせる（境界で意味が途切れないための重なり）
- **決定的な処理：** 同じ入力からは常に同じチャンク列。ベクトル化・重複判定・保存率テストまで、同一単位での一貫処理

第 1 部

ベクトル化

重複候補の「当たり付け」に使う埋め込みモデルの選定工程。固定ペアセット（言い換え 12 件・否定 12 件・無関係 6 件）で 7 モデルを実測し、「分離度」で優劣を判定

日本語の難所 2 点 — 「否定」と「言い換え」— への意図的な照準

固定ペアセット v1 （全て架空の文面）

- 言い換えペア 12 件／否定ペア 12 件／無関係ペア 6 件
- 同一条件でのコサイン類似度の測定（ Muse VM ・ CPU ）

見るべき指標：分離度

- 言い換えの類似度が否定の類似度を上回る組み合わせの割合
- 1.0 で完全分離。対象は絶対値ではなく「順序の正確さ」

この 2 点の難しさの理由

- **否定：** 文末のわずかな違い（〜できる／〜できない）による意味の正反対化と、単語の重なりの同一性。論点は、表層の類似への耐性
- **言い換え：** 語彙や文体の大きな変化と、意味の同一性（「会議の資料は前日までに共有フォルダへ」／「ミーティングで使うファイルは開催日の前日までに共有ドライブに」）。論点は、表層の相違を超えた意味の同一性の捕捉

分離度＝「同じ意味」と「正反対」を、正しく並べられる割合

埋め込みモデルの出力は、文同士の「似てる度（類似度）」を表す 0 〜 1 の数値。

論点は、**同じ意味のペアの、正反対のペアへの優先**の有無。

全組み合わせでの計数と、正しく並んだ割合としての「分離度」。

言い換え（同じ意味）の例

「会議の資料は前日までに共有フォルダへ置いてください」

「ミーティングで使うファイルは、開催日の前日までに共有ドライブにアップしておいてください」

→ 表現の相違と意味の同一。高く出るべき類似度

否定（正反対）の例

「USB メモリの使用は許可されている」

「USB メモリの使用は許可されていない」

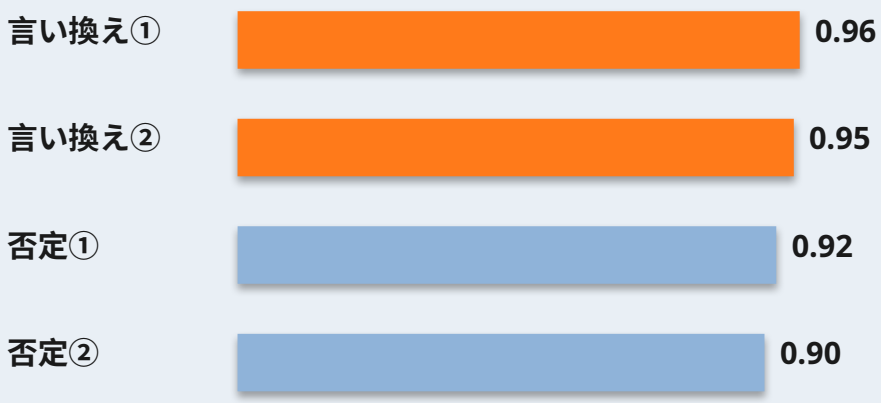
→ 単語の同一と意味の正反対。低く出るべき類似度

分離度の高さと、「正反対のルール」の「重複」への誤認の少なさ。

数え方の図解は次のスライド。

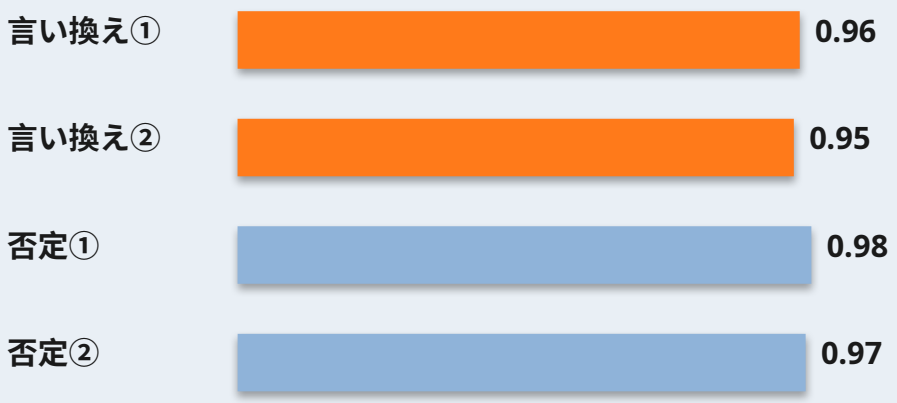
言い換え vs 否定の「対戦」による計数 — 勝ち数の割合＝分離度

良いモデル（イメージ）



対戦：○○○○ 4 勝 0 敗　→ 分離度 4 ÷ 4 = 1.0

悪いモデル（イメージ）



対戦：×××× 0 勝 4 敗　→ 分離度 0 ÷ 4 = 0.0

実測の対戦は、言い換え 12 件 × 否定 12 件 = 144 通り。 ruri-v3-310m は 140 勝 4 敗で分離度 0.972 、 e5-small は 1 勝 143 敗で 0.007 。

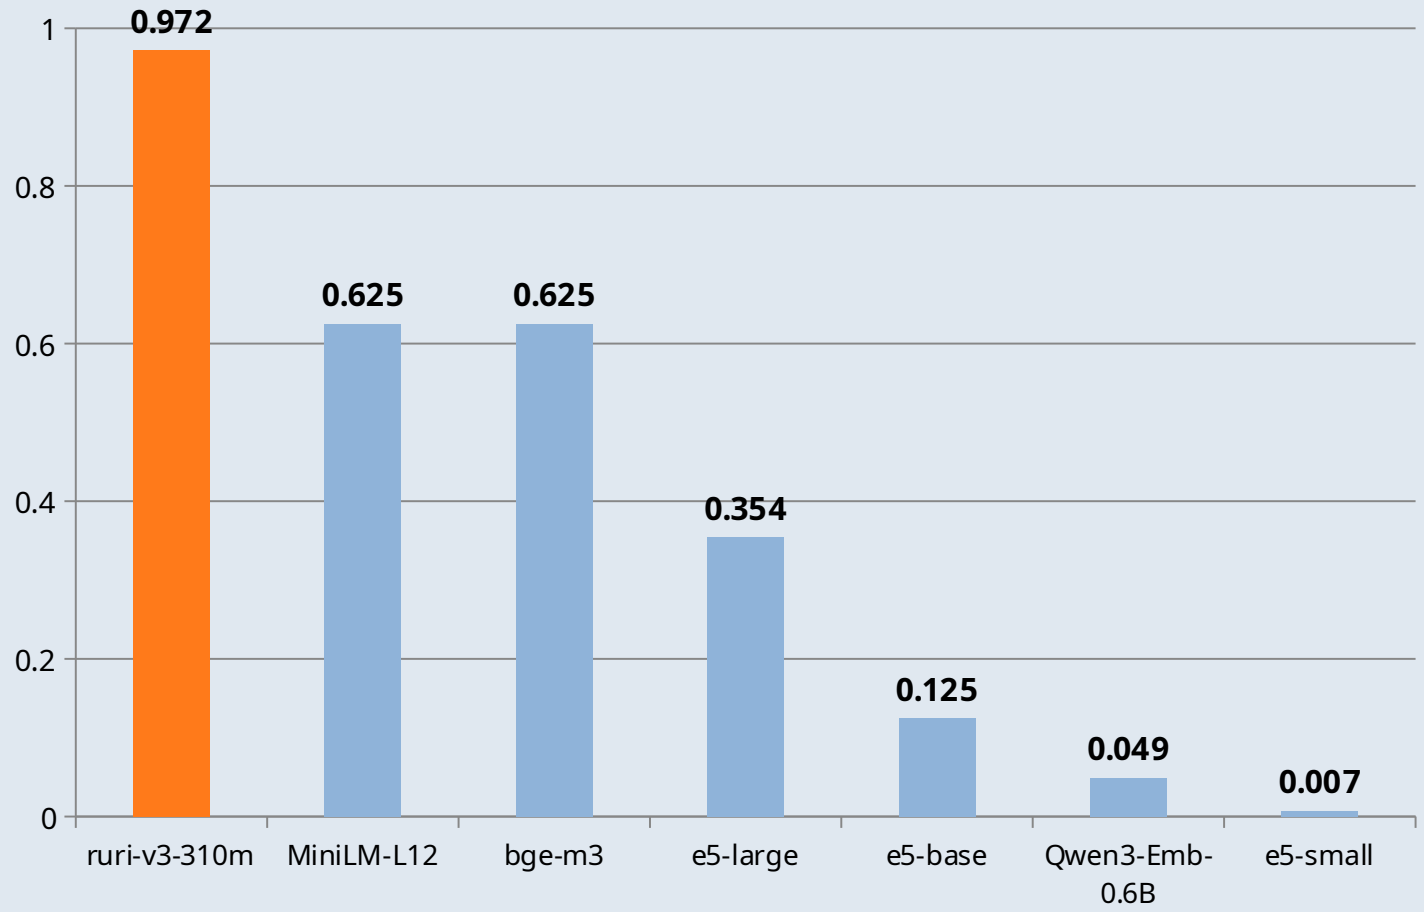
要点は、「似てる度」の絶対値ではなく順序の勝敗。

ruri-v3-310m の突出（分離度 0.972 ）と、 e5 系の否定区別の失敗

モデル	次元	容量 MB	文 / 秒	言い換え	否定	無関係	分離度
ruri-v3-310m	**768**	**1,267**	**7.3**	**0.955**	**0.921**	**0.761**	**0.972**
MiniLM-L12	384	500	46.6	0.819	0.759	0.046	0.625
bge-m3	1,024	2,293	4.4	0.844	0.829	0.434	0.625
e5-large	1,024	2,262	3.7	0.949	0.959	0.795	0.354
e5-base	768	1,134	11.8	0.939	0.967	0.798	0.125
Qwen3-Emb-0.6B	1,024	1,208	8.4	0.768	0.900	0.335	0.049
e5-small	384	493	40.6	0.924	0.974	0.809	0.007

- e5 系 3 モデル全てで、否定平均の言い換え平均への上回り（＝正反対の文への「より似ている」という判定）
- 類似度の絶対値の高さ（ ruri でも無関係ペア 0.761 ）と、固定閾値での線引きの不可能性。順位・相対評価を軸とする設計の必須性の、実測による裏付け

分離度順の歴然たる差 — 0.972 と 0.007 のあいだ



読み取り

- ruri の言い換え平均の最高値（0.955）と、最小値（0.936）の安定性
- MiniLM の最速性能（46.6 文 / 秒）と、言い換えの弱さ。速度用途向けの位置づけ
- Qwen3 の、指示文なし条件での否定区別の不成立（本来の使い方では変動の可能性）

表層に騙された例と、 ruri でも際どく競った例

表層に騙された例（ e5-small ）

「 USB メモリの使用は許可されている」

「 USB メモリの使用は許可されていない」

→ 類似度 **0.989**

自モデルの言い換え平均（ 0.924 ）を超える値。正反対の文への、言い換え同士以上の「類似」の判定。 Qwen3 の最悪例も「社外に公開できる／できない」で 0.973

際どく競った例（ ruri-v3-310m ）

「会議室は予約なしで使える」

「会議室は予約なしでは使えない」

→ 類似度 **0.945**

言い換え平均（ 0.955 ）の下回りと、言い換え最小値（ 0.936 ）の上回り。この僅差の数件のみの逆転による、分離度 0.972 （ 1.0 ではなく）

第 2 部

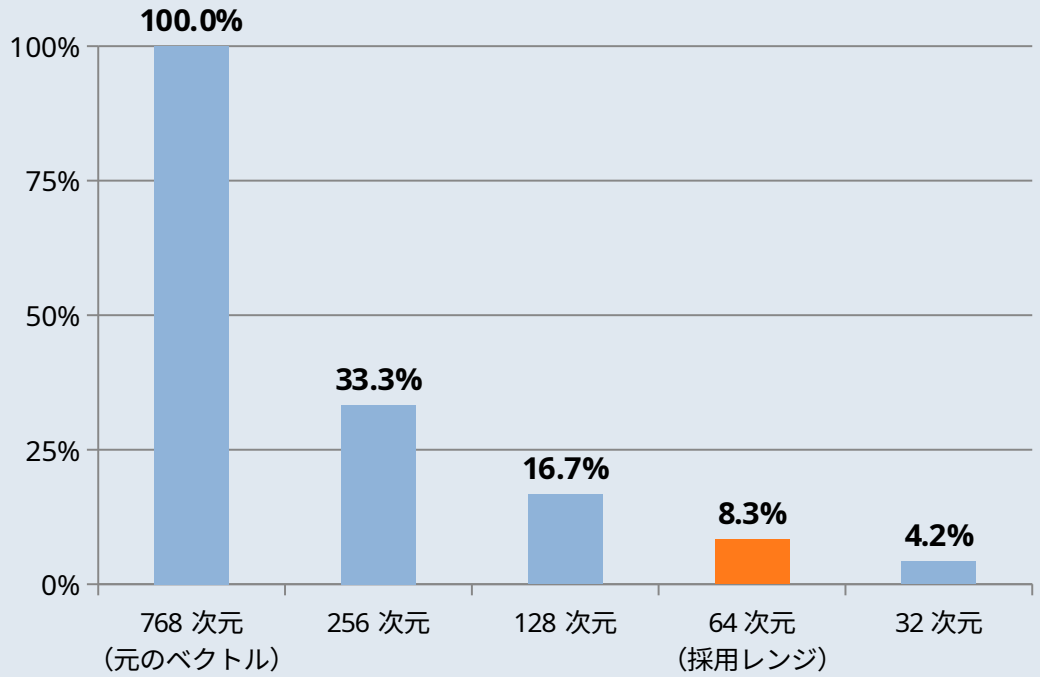
次元削減と比較

圧縮後も類似度の順序が壊れない方式の実測比較。中心化する PCA での崩壊と、中心化しない切り捨て SVD での分離度不変の確認

高次元ベクトルの計算量の肥大と、その抑制

- 1 チャンク＝ 768 次元のベクトル。全チャンク同士の比較は「ペア数 × 次元数」の計算量
- 対象は全 md ファイルで、チャンク数は増え続ける。ペア数はチャンク数の 2 乗の速さで増加
- 実行環境は CPU のみ（GPU なし）。次元を下げない一巡の計算は、対象の増加とともに肥大
- 次元削減による、計算量とメモリの次元比どおりの圧縮（768 → 64 で約 1/12 ）

次元数と計算量の関係（比例・相対値）



コサイン類似度の計算量は次元数に比例。 768 次元を 100% とした相対値

ただし、圧縮で「意味の順序」が壊れては本末転倒。方式の選定と検収は次のページ — 物差しは分離度

次元削減の方式比較と、 SVD の採用

PCA （中心化あり）で圧縮

言い換えペアの類似度が **0.943 → 0.253** への崩壊と、重複候補 0 件。

中心化とは原点そのものの移転。コサイン類似度は「原点から見た角度」のため、全ベクトルの角度の組み替えが発生。

SVD （中心化なし・切り捨て）で圧縮

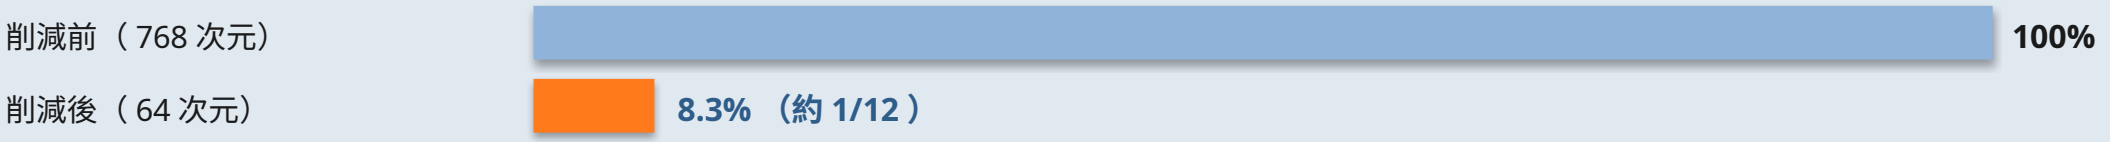
圧縮の前後で **分離度 0.972 が不変**。実測での確認。

原点を動かさない圧縮のため、角度＝「意味の近さ」の順序を保持。

なぜ SVD を採用したか

- **目的との適合：** 用途は「圧縮して、そのままコサイン類似度で比べる」こと。原点を動かさない SVD のみが、類似度の順序を保ったまま圧縮可能
- **実測の裏付け：** 圧縮前後での分離度 0.972 の不変（ PCA では 0.943 → 0.253 への崩壊）。選定と検収の物差しは分離度で統一
- **PCA の位置づけ：** PCA 自体の劣位ではなく、組み合わせへの適合の問題。分散の分析など中心化が要る用途では PCA が正
- **次元数の決定：** 累積寄与率とエルボー法による、「情報をどれだけ残すか」の側からの決定（採用レンジは 64 次元）

計算量の変化（次元削減の前後・コサイン類似度の総計算量）



付録

分離度を詳しく読む

分離度の「逆転件数」と「平均の差」という、２つの読み筋

「逆転件数」への換算による、モデル差のさらなる明確化

モデル	分離度	正しい順序	逆転	言い換え平均	否定平均	差（マージン）
ruri-v3-310m	**0.972**	**140 件**	**4 件**	**0.955**	**0.921**	**+0.033**
MiniLM-L12	0.625	90 件	54 件	0.819	0.759	+0.060
bge-m3	0.625	90 件	54 件	0.844	0.829	+0.015
e5-large	0.354	51 件	93 件	0.949	0.959	−0.010
e5-base	0.125	18 件	126 件	0.939	0.967	−0.028
Qwen3-Emb-0.6B	0.049	7 件	137 件	0.768	0.900	−0.132
e5-small	0.007	1 件	143 件	0.924	0.974	−0.050

- 定義：言い換え 12 件 × 否定 12 件 = 144 通りの総当たりで、言い換えの類似度が否定を上回る割合
- e5-small は 144 通り中 143 通りの逆転。平均値上は双方「高い類似度」で、順序はほぼ全滅の状態

「平均の差」が最大のモデルが、分離度では負ける理由

MiniLM-L12 の「言い換え平均 − 否定平均」の差は +0.060 と最大級でも、分離度は 0.625 。 ruri は差 +0.033 と約半分で、分離度は 0.972 。

理由は分布の広がり（標準偏差）。 MiniLM は 0.10 〜 0.14 と広く、平均の隔たりと個別ペアでの大きな重なりの併存。 ruri は 0.011 〜 0.014 と極めて狭く、分布の重なりのほぼ皆無。

重複候補の検出とは、「平均」ではなく「1 ペアごと」の判断の積み重ね。ゆえに良し悪しの物差しは、平均の差ではなく、個別ペアでの順序の誤りの頻度 — すなわち分離度。

ruri の逆転 4 件の正体

発生は、最難の否定 0.945 と最弱の言い換え 0.936 の僅差ゾーン（差 0.009 ）のみ。

この帯域は測定誤差の範囲につき、モデルの優劣での解消は不可能。

ゆえに自動統合はなし。僅差ゾーンを人の判断に残す設計こそ、分離度 0.972 の正しい読み方。

まとめ

決定事項と、設計に残した原則

決定事項（ 2026 年 11 月 8 日・本人確定）

- **埋め込み：** cl-nagoya/ruri-v3-310m の採用（設定値としての保持と、差し替え可能性）
- **次元削減：** 中心化しない切り捨て SVD の採用
- 本資料の格納先： entropy-reduction リポジトリ reports/ （エントロピー削減レポート .pdf ）

原則と限界

- 埋め込みは候補の当たり付けまで。統合の最終判定は証拠つきの判定＋本人の仕分け（ fail-closed ）
- 分離度は「モデル × ペアセット」の値。ペアセット v1 は架空文 30 件の固定セットであり、別の文面では変動の可能性
- 行数・削減率は非目標。対象は意味の保存率のみ

出典： 第 1 部 entropy-reduction リポジトリ bench/v-emb/results.json ・ results_qwen.json ／第 2 部 AI 組織 Issue #19 P2 完了報告（ GitHub Issue コメント）。数値はすべて実測ファイルからの直接生成。