AI 組織 Issue #19 「エントロピー削減の仕組み」

エントロピー削減レポート

モデル選定の実測と、次元削減・分離度の図解

埋め込みモデル 7 モデル実測（採用： ruri-v3-310m ）／次元削減は中心化しない SVD ／分離度の付録つき

実測日： 2026 年 11 月 8 日（ Muse VM ・ CPU 実測）／分離度の付録： 2026 年 11 月 10 日 追加

EXECUTIVE SUMMARY

結論：採用モデルは実測で決めた。判定は「順位」と「人の仕分け」で担保する

第 1 部｜埋め込みモデル

ruri-v3-310m を採用

分離度 0.972 で 7 モデル中突出。言い換え平均も最高（0.955）。日本語特化モデルが、否定の区別という最難関で唯一実用水準に達した。

運用｜判定と保存

自動で決めず、人の仕分けで担保

埋め込みは候補の当たり付けまで。削減の実行は本人の仕分け済みの行だけに限定し（fail-closed）、実行後は保存率テストで意味が残ったかを検収する。

第 2 部｜次元削減

中心化しない SVD を採用

中心化（PCA）では類似度が崩壊（0.943 → 0.253）。SVD では圧縮前後で分離度 0.972 が不変であることを実測で確認した。

共通の原則：類似度の固定閾値で自動判定しない。埋め込みは候補の当たり付けまで、最終判定は証拠つきの判定と本人の仕分けに残す。

背景

文書は「足す」ばかりで「減らす」が起きない — だから仕組みで減らす

エントロピーが増え続ける理由

- 新しい決め事・例外・事故の教訓は、その都度どこかへ書き足されていく
- 一方「減らす」操作は、意識して仕組みにしない限り起きない
- この非対称により、文書の総量は増える一方になる（＝エントロピーの増加）
- 本人の原則：「長すぎる md ファイルは有害」— 長い文書は漏れ・解釈ブレ・矛盾を招く

運用の分担

- **週次の削減サイクル＝「治療」**：候補の仕分けと削減の実行
- **月次の棚卸し＝「健康診断」**：検出と深い点検

増え続けることの問題

密度の低下

量が増えるほど 1 件あたりの注意が薄まり、大事なルールが埋もれる

矛盾の増加

同じ内容が複数箇所にあると、片方だけ更新されて食い違う

実質的な無効化

探せない・読み切れないルールは「無い」のと同じ。例外や教訓ほど埋もれやすい

静かな劣化

少しずつ進むため気づきにくく、判断のぶれや作業漏れで表面化する

仕組みの全体像

削減サイクルは 9 段階。意味の保存が絶対の制約



再計測の結果は、次のサイクルの「測る（元の文章）」へ戻る ― 週次でこの輪を回し続ける

- 測る → 候補を出す → 本人が仕分ける → 削減を実行 → 測り直す、までをコードで担保する（疎結合な小単位の組み合わせ）
- **保存率テスト：** 削減前の文書から作った固定の質問セットに、削減後の文書だけで答えられるかを測る。保存率が合格ライン未満なら削減は不合格
- 到達可能性は 100% を維持（コードへ移した記述も「到達できる」ものとして数える）
- 行数・削減率は目標にしない。守るのは意味であって、短さそのものではない

第 1 部

埋め込みモデル比較

重複候補の「当たり付け」に使うモデルを、固定ペアセットで 7 モデル実測した

日本語の難所 2 点 — 「否定」と「言い換え」— を意図的に突く

固定ペアセット v1 （全て架空の文面）

- 言い換えペア 12 件／否定ペア 12 件／無関係ペア 6 件
- 同一条件でコサイン類似度を測定（ Muse VM ・ CPU ）

見るべき指標：分離度

- 言い換えの類似度が否定の類似度を上回る組み合わせの割合
- 1.0 で完全分離。絶対値ではなく「順序の正確さ」を見る

なぜこの 2 点が難しいのか

- **否定：** 文末のわずかな違い（〜できる／〜できない）で意味が正反対になるのに、単語の重なりはほぼ同じ。表層の似せに騙されないかが問われる
- **言い換え：** 語彙や文体が大きく変わっても意味は同じ（「会議の資料は前日までに共有フォルダへ」／「ミーティングで使うファイルは開催日の前日までに共有ドライブに」）。表層が違っても意味の同一性を捉えられるかが問われる

分離度＝「同じ意味」と「正反対」を、正しく並べられる割合

埋め込みモデルは、 2 つの文がどれだけ似ているかを 0 〜 1 の数（類似度）で返します。
分離度は、その類似度を使って「言い換え（同じ意味）のペア」と「否定（正反対）のペア」を比べたとき、
言い換えの方が高い類似度になる — つまり順序が正しくなる — 組み合わせの割合です。

言い換え（同じ意味）の例

「会議の資料は前日までに共有フォルダへ置いてください」

「ミーティングで使うファイルは、開催日の前日までに共有ドライブにアップしておいてください」

→ 表現は違うが意味は同じ。類似度は高く出てほしい

否定（正反対）の例

「 USB メモリの使用は許可されている」

「 USB メモリの使用は許可されていない」

→ 単語はほぼ同じだが意味は正反対。類似度は低く出てほしい

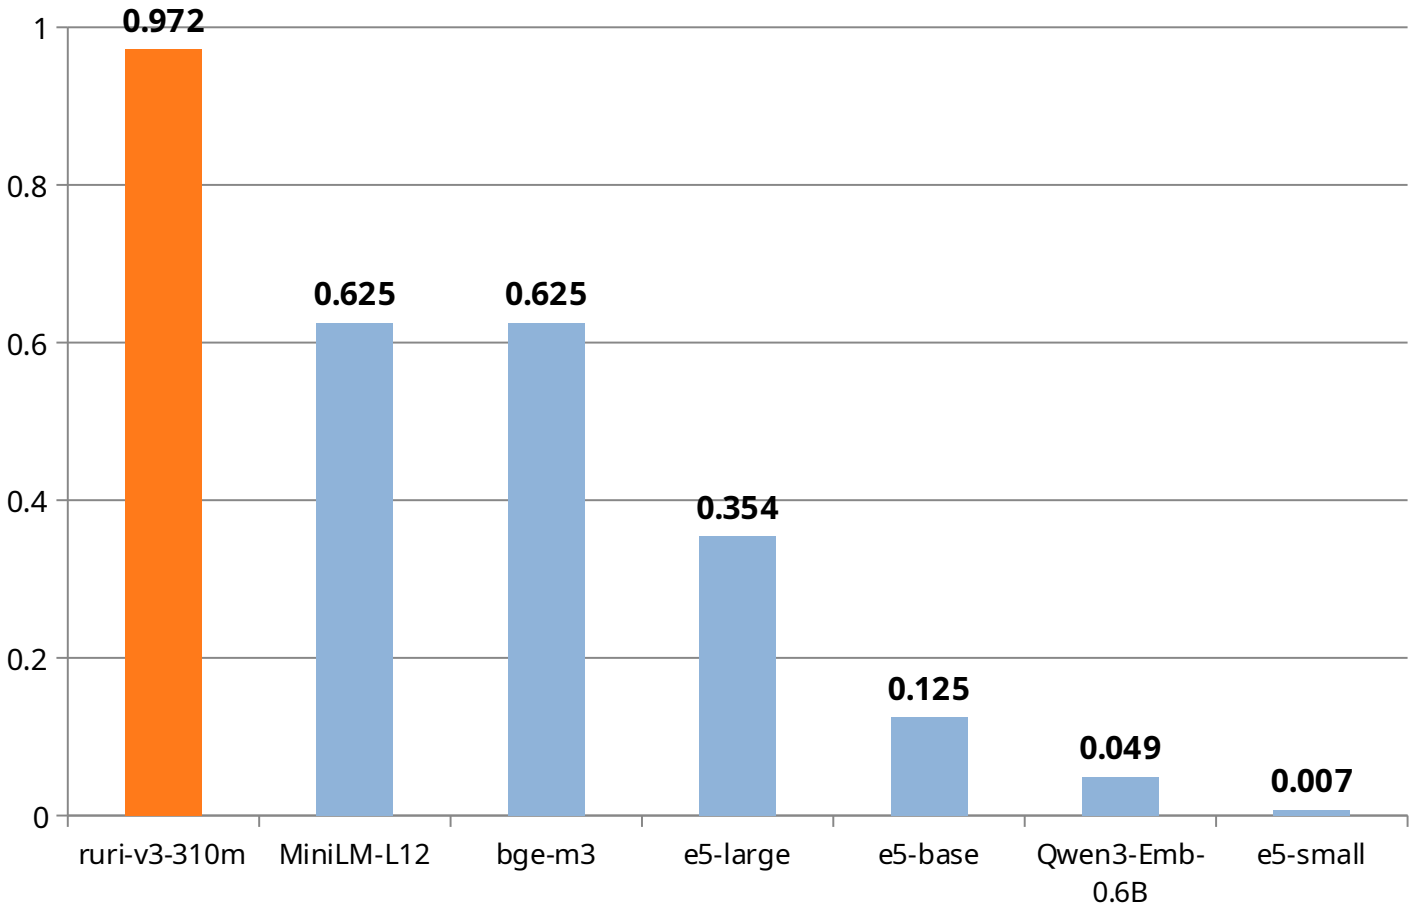
小さな例： 言い換えの類似度が [0.96, 0.95] 、否定が [0.92, 0.90] なら、比べる 4 通り全部で言い換えが勝ち → 分離度 1.0 。
逆に否定が [0.98, 0.97] と高く出るモデルは全部負け → 分離度 0 。正反対のルールを「重複」と誤検出する危険なモデルです。

ruri-v3-310m が分離度 0.972 で突出。 e5 系は否定の区別に失敗した

モデル	次元	容量 MB	文 / 秒	言い換え	否定	無関係	分離度
ruri-v3-310m	**768**	**1,267**	**7.3**	**0.955**	**0.921**	**0.761**	**0.972**
MiniLM-L12	384	500	46.6	0.819	0.759	0.046	0.625
bge-m3	1,024	2,293	4.4	0.844	0.829	0.434	0.625
e5-large	1,024	2,262	3.7	0.949	0.959	0.795	0.354
e5-base	768	1,134	11.8	0.939	0.967	0.798	0.125
Qwen3-Emb-0.6B	1,024	1,208	8.4	0.768	0.900	0.335	0.049
e5-small	384	493	40.6	0.924	0.974	0.809	0.007

- e5 系 3 モデルは全て、否定平均が言い換え平均を上回った（＝正反対の文を「より似ている」と判定）
- 類似度の絶対値は全体に高い（ ruri でも無関係ペア 0.761 ）。固定閾値での線引きはできず、順位・相対評価を軸にする設計が必須と実測が裏付けた

分離度で並べると差は歴然 — 0.972 と 0.007 のあいだ



読み取り

- ruri は言い換え平均も最高（0.955）、最小値（0.936）も最も安定
- MiniLM は最速（46.6 文 / 秒）だが言い換えが弱い。速度用途向けの位置づけ
- Qwen3 は指示文なし条件では否定を区別できず（本来の使い方では変わりうる）

表層に騙された例と、 ruri でも際どく競った例

表層に騙された例（ e5-small ）

「 USB メモリの使用は許可されている」

「 USB メモリの使用は許可されていない」

→ 類似度 **0.989**

自モデルの言い換え平均（ 0.924 ）より高い値。正反対の文を、言い換え同士より“似ている”と判定したことになる。 Qwen3 の最悪例も「社外に公開できる／できない」で 0.973 。

際どく競った例（ ruri-v3-310m ）

「会議室は予約なしで使える」

「会議室は予約なしでは使えない」

→ 類似度 **0.945**

言い換え平均（ 0.955 ）は下回ったが、言い換えの最小値（ 0.936 ）よりは上。この僅差の数件だけが逆転し、分離度は 1.0 でなく 0.972 になった。

PCA と SVD の違いは「中心化」だけ — そしてそれが決定的だった

中心化する PCA で圧縮したところ

言い換えペアの類似度が **0.943 → 0.253** に崩壊し、重複候補は 0 件になった。

コサイン類似度は「原点から見た角度」。中心化は原点そのものを引っ越す操作なので、全ベクトルの角度が組み替わってしまう。

中心化しない切り捨て SVD では

圧縮の前後で **分離度 0.972 が不変** であることを実測で確認。

PCA が劣っているのではない。「圧縮して、そのままコサイン類似度で比べる」という目的と測り方の組み合わせでは、中心化しない SVD が合っていた、という結論。

- **次元数の決め方：** 累積寄与率とエルボー法で「情報をどれだけ残すか」の側から決める
- 圧縮で壊れやすいのは絶対値ではなく順序。だから検収も順序（分離度）で見る — 選定と検収で物差しを統一した

分離度を「逆転件数」に直すと、モデルの差はさらに明確になる

モデル	分離度	正しい順序	逆転	言い換え平均	否定平均	差（マージン）
ruri-v3-310m	**0.972**	**140 件**	**4 件**	**0.955**	**0.921**	**+0.033**
MiniLM-L12	0.625	90 件	54 件	0.819	0.759	+0.060
bge-m3	0.625	90 件	54 件	0.844	0.829	+0.015
e5-large	0.354	51 件	93 件	0.949	0.959	−0.010
e5-base	0.125	18 件	126 件	0.939	0.967	−0.028
Qwen3-Emb-0.6B	0.049	7 件	137 件	0.768	0.900	−0.132
e5-small	0.007	1 件	143 件	0.924	0.974	−0.050

- 定義：言い換え 12 件 × 否定 12 件 = 144 通りの総当たりで、言い換えの類似度が否定を上回る割合
- e5-small は 144 通り中 143 通りが逆転。平均値だけ見れば両方「高い類似度」に見えるが、順序はほぼ全滅している

「平均の差」が最大のモデルが、分離度では負ける理由

MiniLM-L12 は言い換え平均 − 否定平均の差が +0.060 と最大級だったのに、分離度は 0.625 。 ruri は差が +0.033 と約半分で、分離度は 0.972 。

理由は分布の広がり（標準偏差）。 MiniLM は 0.10 〜 0.14 と広く、平均では離れていても個別のペアでは大きく重なる。 ruri は 0.011 〜 0.014 と極めて狭く、分布がほぼ重ならない。

重複候補の検出は「平均」ではなく「１ペアごと」の判断の積み重ね。だから良し悪しは平均の差ではなく、個別のペアで順序を間違える頻度 — すなわち分離度 — で測る必要がある。

ruri の逆転 4 件の正体

最難の否定 0.945 と最弱の言い換え 0.936 がぶつかる僅差ゾーン（差 0.009 ）でのみ発生。

この帯域は測定誤差の範囲であり、モデルの優劣では解消できない。

だから自動統合はしない。僅差ゾーンは人の判断に残す設計が、分離度 0.972 の正しい読み方。

まとめ

決定事項と、設計に残した原則

決定事項（2026 年 11 月 8 日・本人確定）

- **埋め込み：** cl-nagoya/ruri-v3-310m を採用（設定値として保持し、差し替え可能）
- **次元削減：** 中心化しない切り捨て SVD を採用
- 本資料は entropy-reduction リポジトリ reports/ に格納（エントロピー削減レポート .pdf ）

原則と限界

- 埋め込みは候補の当たり付けまで。統合の最終判定は証拠つきの判定＋本人の仕分け（ fail-closed ）
- 分離度は「モデル × ペアセット」の値。ペアセット v1 は架空文 30 件の固定セットで、別の文面では変わりうる
- 行数・削減率は目標にしない。守るのは意味の保存率

出典： 第 1 部 entropy-reduction リポジトリ bench/v-emb/results.json ・ results_qwen.json ／第 2 部 AI 組織 Issue #19 P2 完了報告（ GitHub Issue コメント）。数値はすべて実測ファイルから直接生成。